

“Clasificación ordinal de huevos de *Aedes aegypti* en ovitrampas: Un análisis comparativo mediante CNN”

Autores: Rodrigo Carbajal, Jorge Chamorro, Pedro Chavez, Nassim Ramirez, Gonzalo Ipanaque

Resumen- Este trabajo aborda la complejidad epidemiológica manual del mosquito del dengue, un proceso lento, agotador y propenso a errores humanos, proponiendo automatizar el conteo de sus huevos. El objetivo fue comparar tres redes neuronales convolucionales para estimar cantidades y clasificar la infestación según el Índice de Densidad de Huevos. Se utilizaron imágenes de un laboratorio brasileño junto con técnicas de aumento de datos para evitar el sobreajuste. La arquitectura InceptionV3 resultó inestable con un error absoluto medio de 24.78. ResNet-50 obtuvo el menor error global con 14.12, pero EfficientNet-B3 demostró superioridad en densidades críticas al predecir 339 huevos frente a un solapamiento real de 382. Se concluye que EfficientNet-B3 ofrece el mejor balance operativo; sus desviaciones ocurren exclusivamente entre categorías adyacentes del Índice de Densidad de Huevos, evitando falsos negativos extremos y garantizando confiabilidad para agilizar alertas epidemiológicas.

1. Introducción

El dengue es una enfermedad infecciosa transmitida por el mosquito *Aedes aegypti*, que afecta al Perú, principalmente a las regiones de la selva y la costa norte, tales como San Martín, Ucayali, Loreto, Piura y Tumbes (CDC Perú, 2026). El Centro Nacional de Epidemiología, Prevención y Control de Enfermedades (CDC Perú), ante los miles de casos reportados en el país (273847, en la semana epidemiológica de 2024), emite alertas epidemiológicas con el fin de gestionar medidas preventivas para el control y monitoreo de la población afectada con el dengue (CDC Perú, 2024).

El uso de ovitrampas constituye el principal mecanismo adoptado en el Perú para la vigilancia entomológica de los mosquitos transmisores del dengue a través de los huevos que los zancudos depositan en estas paletas (MINSA, 2023). La Figura 1 muestra una paleta de ovitrampa con huevos de *Aedes aegypti* y un acercamiento a un huevo individual, el cual constituye el objeto de estudio de este trabajo. Actualmente, el conteo de los huevos es realizado por personas capacitadas para esta tarea y usando dispositivos costosos como lo son los microscopios; además, se reporta que esta tarea es agotadora, toma tiempo y es susceptible al error e inconsistencia en la cuenta cuando es realizado por diferentes profesionales (De Santana, et al., 2019). Ante esa situación, la automatización de la tarea de conteo mediante la inteligencia artificial permitiría acelerar los procesos de diagnóstico, reducir costos operativos y de instrumentos, y podría ser implementada en zonas de difícil acceso.



(a)

(b)

Figura 1. (a) Imagen de una paleta de ovitrampa con huevos de *Aedes aegypti*. (b) Acercamiento de un huevo individual utilizado como objeto de detección

En ese sentido, este trabajo propone la comparativa de tres redes neuronales convolucionales (CNN) con Transfer Learning para el conteo de huevos. Ya que este número es usado para clasificar la ovitrampa según el Índice de Densidad de Huevos (IDH), las cuales son las cuatro clasificaciones dadas por el MINSA: Bajo, Medio, Alto y Muy Alto (MINSA, 2016). El entrenamiento de las arquitecturas CNN se realizará con imágenes de los datasets realizados por el laboratorio en Brasil (Vicente et al., 2025).

a. Hipótesis y/o pregunta a abordar

¿Cuál de las tres arquitecturas de redes neuronales convolucionales con Transfer Learning (ResNet-50, InceptionV3 y EfficientNet-B3) obtiene el mejor desempeño en el conteo de huevos de *Aedes aegypti* en imágenes de ovitrampas y en la clasificación del Índice de Densidad de Huevos (IDH) según las categorías establecidas por el MINSA?

b. Objetivos

Objetivo General

Comparar el desempeño de tres arquitecturas CNN con transfer learning (ResNet-50, InceptionV3 y EfficientNet-B3) para el conteo de huevos de *Aedes aegypti* en imágenes de ovitrampas y su clasificación según el Índice de Densidad de Huevos (IDH) establecido por el MINSA.

Objetivos específicos

- Preprocesar y adaptar el dataset de imágenes de ovitrampas del laboratorio en Brasil para el entrenamiento y evaluación de las tres arquitecturas CNN propuestas.
- Entrenar las tres arquitecturas CNN con fine-tuning, adaptando la última capa para la tarea de conteo de huevos automatizado.
- Evaluar y comparar el desempeño de las tres arquitecturas utilizando métricas de regresión (RMSE: Error Cuadrático Medio, MAE: Error Absoluto Medio, MdAE: Mediana del Error



Absoluto) para el conteo automático de huevos, y validar la correcta asignación del nivel de riesgo epidemiológico (IDH) mediante el análisis de matrices de confusión.

- Identificar la arquitectura CNN con mejores métricas en la tarea de clasificación según IDH y considerando también la eficiencia computacional para su implementación en zonas de pocos recursos en Perú.

2. Trabajos relacionados

El análisis automatizado de ovitrampas microscópicas y macroscópicas se ha abordado predominantemente mediante dos paradigmas de visión computacional basados en aprendizaje profundo (Deep Learning): la detección de objetos por cajas delimitadoras (bounding boxes) y la segmentación de instancias por máscaras de píxeles. Ambos enfoques exhiben un rendimiento sobresaliente en condiciones controladas de baja densidad, pero presentan un decaimiento crítico al enfrentarse a la morfología y agrupamiento de los huevos de vectores.

Por un lado, en el ámbito de la clasificación morfológica de parásitos diminutos, Leopoldo y Leones (2025) desarrollaron un enfoque híbrido secuencial denominado aprendizaje por transferencia acoplado (Stacked Transfer Learning). Esta arquitectura delega la localización espacial inicial a la red monocapa YOLOv8 y, posteriormente, extrae las características geométricas y de textura fina de la región de interés (ROI) mediante una red residual ResNet-50. El éxito de este método radicó en la separación de tareas: YOLOv8 actúa como un proponente de regiones robusto, mitigando la tasa de falsos positivos causados por artefactos del fondo, mientras que ResNet-50 explota las conexiones de salto (skip connections) para resolver la sutil ambigüedad visual entre especies con alta precisión. No obstante, este diseño asume una premisa ideal: que los objetos de interés se encuentran distribuidos de manera discreta y aislada dentro del campo microscópico, permitiendo que el algoritmo de supresión de no máximos (NMS) aisle un único cuadro delimitador por entidad biológica.

Por otro lado, al trasladar el problema específicamente hacia la vigilancia entomológica del vector del dengue, Javed et al. (2023) implementaron EggCountAI, un sistema fundamentado en la arquitectura de dos etapas Mask R-CNN enfocado en la segmentación de instancias de huevos de *Aedes aegypti*. A diferencia del modelo secuencial de Leopoldo y Leones (2025), Mask R-CNN aborda la localización y la segmentación detallada a nivel de píxel de manera simultánea mediante una rama de máscara paralela a la regresión del cuadro delimitador. En su evaluación cuantitativa, Javed et al. (2023) demostraron que este enfoque supera holgadamente a las técnicas tradicionales de umbralización de intensidad y filtros morfológicos (tales como MECVision o el software Count), logrando precisiones elevadas en imágenes de baja densidad. Sin embargo, los autores identificaron y reportaron una limitación matemática severa: el rendimiento de la red decae abruptamente cuando los huevos se presentan superpuestos o aglomerados en clusters. Al

ser los huevos de *Aedes aegypti* entidades negras, elípticas y opacas, su amontonamiento físico en las paletas elimina los gradientes de contraste y los bordes definidos entre ellos, lo que provoca que Mask R-CNN fusione múltiples huevos en una sola máscara o los omita por completo debido a la ambigüedad en la propuesta de regiones de interés.

Al comparar críticamente ambas metodologías, se evidencia una brecha conceptual en la literatura. Mientras que el acoplamiento YOLOv8 + ResNet-50 de Leopoldo y Leones (2025) demuestra que las arquitecturas convolucionales clásicas de clasificación profunda son excepcionales para asimilar texturas complejas, su dependencia de un detector de cajas delimitadoras lo vuelve inviable para escenarios densos. Por su parte, la segmentación de Mask R-CNN planteada por Javed et al. (2023) confirma que el conteo unitario basado en la individualización geométrica de cada huevo falla sistemáticamente ante el fenómeno del solapamiento masivo en infestaciones severas. Ninguno de los dos enfoques logra resolver el compromiso entre el conteo preciso en alta densidad y la viabilidad del etiquetado de datos, dado que delimitar miles de cajas o máscaras poligonales para el entrenamiento genera un costo inasumible en tiempo y es propenso al error humano.

Por otro lado, Vicente et al. (2025) demostraron que el conteo de huevos de *Aedes aegypti* puede formularse de manera efectiva como una tarea de detección de objetos mediante redes neuronales profundas. En dicha investigación, se construyó un conjunto de datos propio con 247 imágenes tomadas tanto en condiciones de campo como de laboratorio y 12,513 huevos anotados, lo cual fortalece el estudio para escenarios reales. Esto es importante porque el problema no es solo detectar huevos separados, sino estimar con precisión la cantidad de huevos en imágenes con alta densidad, solapamiento y variabilidad visual.

En el artículo se comparan tres arquitecturas representativas de la detección de objetos: Faster R-CNN, SABL y FoveaBox (Vicente et al., 2025). Faster R-CNN funciona de la manera más común, siendo de dos etapas. Luego, SABL introduce una estrategia de localización más fina a partir de la predicción de bordes por buckets; y FoveaBox representa un enfoque anchor-free, lo que significa que prescinde de las cajas de anclaje convencionales utilizadas en modelos previos, apoyándose exclusivamente en la predicción del centro geométrico del objeto y sus límites. En el experimento, FoveaBox obtiene el mejor desempeño global con una mediana de MAE de 6.854 y RMSE de 19.725, mientras que Faster R-CNN logra 8.958 y 28.678, y SABL presenta el rendimiento más bajo con 11.146 y 36.301, respectivamente. Además, FoveaBox alcanza la mayor correlación de Pearson con una media de 0.989, lo cual demuestra una excelente predicción (Vicente et al., 2025).

El estudio sugiere una tendencia favorable hacia FoveaBox, pero no prueba de manera absoluta que esta arquitectura sea superior en todos los contextos.



Esto es importante porque evita afirmar algo que no es y permite dar una decisión razonada por evidencia empírica, pero aún condicionada por el tamaño del dataset, la naturaleza de las imágenes y las decisiones experimentales adoptadas. Para un mejor análisis, el artículo también muestra limitaciones relevantes que cabe destacar en el informe.

Primero, el dataset sigue siendo relativamente pequeño para el experimento, componiéndose de 247 imágenes, insuficientes para una generalización robusta, sobre todo si se pretende extrapolar a otros entornos, condiciones de iluminación o tipos de superficie. En segundo lugar, las imágenes se obtuvieron con microscopio y eso restringe la variedad de escenarios reales. En tercer lugar, los autores utilizan pesos preentrenados de COCO, mantienen la mayoría de hiperparámetros por defecto y no realizan una búsqueda exhaustiva de ajuste fino. Lo que significa que los resultados reflejan una validación seria, pero no una optimización máxima de cada arquitectura. Por eso, el trabajo es más fuerte como benchmark comparativo que como solución final cerrada (Vicente et al., 2025).

El artículo también evidencia que el error de conteo crece al igual que la densidad de huevos (Vicente et al., 2025). Incluso en imágenes con menos de 50 huevos, el RMSE sigue siendo suficientemente alto como para ser preocupante si el objetivo es usar el conteo en predicción epidemiológica o análisis científico. Esto es importante porque no basta con tener una red que encuentre objetos, sino que debe soportar escenarios de alta congestión visual, donde pequeñas omisiones o falsas detecciones alteran de manera significativa el conteo final. Esto implica que las métricas de detección por sí solas no son suficientes.

Además, los autores señalan que una de las mayores dificultades aparece en los huevos ubicados en los bordes de la paleta, porque su anotación es ambigua y su detección por la red es más inestable, muy aparte de los problemas cuando los huevos están desenfocados, parcialmente ocultos o confunden al detector por estar muy próximos a suciedad o irregularidades del soporte. Incluso muestran casos en los que la red detecta suciedad como si fueran huevos, es decir, falsos positivos ligados a la textura y al contraste (Vicente et al., 2025). Esto es valioso porque demuestra que el problema no es meramente cuantitativo, sino también semántico y geométrico. La red debe aprender a distinguir estructuras biológicas pequeñas de ruido visual, sombras, bordes y residuos del entorno, añadiendo más puntos a considerar en el trabajo final.

En conclusión, se deben priorizar arquitecturas capaces de manejar objetos pequeños, densos y cercanos. La superioridad relativa de FoveaBox sugiere que un enfoque anchor-free puede ser más apropiado que un detector clásico de dos etapas cuando el objetivo principal es el conteo preciso en imágenes densamente pobladas (Vicente et al., 2025). Sin embargo, el estudio también deja claro que aún persisten errores considerables en escenarios

complejos, por lo que se busca una propuesta más aplicada para complementar la arquitectura elegida con estrategias de mejora del dataset, aumento de datos, revisión de anotaciones, análisis de errores y, posiblemente, ajustes específicos para conteo, no solo para detección. Esto se logrará con una combinación de arquitectura, calidad de datos y diseño experimental robusto.

Por otra parte, en un dominio médico enfocado en la detección de patrones sutiles sobre fondos complejos, Nuipian et al. (2023) abordaron la clasificación de enfermedades que causan discapacidad visual, como cataratas, glaucoma o retinopatía diabética, y la creciente necesidad de algoritmos de IA avanzados capaces de analizar datos de imágenes que están fuera del alcance de métodos convencionales.

En el documento, se realiza un estudio comparativo utilizando las arquitecturas ResNet-50, InceptionV3 y EfficientNet-B3 para evaluar su efectividad en la extracción de características complejas mediante el paradigma de transfer learning.

- ResNet-50: Esta red se creó para abordar problemas de desaparición de gradientes en redes neuronales profundas, gracias a la implementación de "conexiones residuales o de salto". La arquitectura de ResNet50 consta de aproximadamente 50 capas, lo que es una amalgama de capas convolucionales, capas agrupadas y capas completamente conectadas (Nuipian et al., 2023).
- InceptionV3: Esta arquitectura está diseñada para ser computacionalmente eficiente, manteniendo al mismo tiempo una alta precisión. Consta de múltiples ramas paralelas y cada una presenta su conjunto de filtros convolucionales de diferentes tamaños. Esta técnica se utiliza para la variabilidad de escala en los hallazgos médicos, permitiendo capturar anomalías masivas, así como microlesiones puntuales en la retina.
- EfficientNet-B3: Este modelo utiliza un método de escalamiento compuesto para ampliar automáticamente la arquitectura del modelo, en términos de profundidad y ancho, en función de la resolución de la imagen de entrada (Nuipian et al., 2023).

Finalmente, los resultados del estudio atribuyen que el escalamiento compuesto de EfficientNet-B3 se adapta mejor a la detección y categorización precisa de enfermedades en la retina. Con este modelo se obtuvo una precisión del 99 % en el entrenamiento y un 96 % en las pruebas. Este trabajo es relevante para este trabajo de clasificación de huevos de mosquito, ya que requiere identificar cuerpos diminutos y diferenciar patrones sutiles entre diferentes tipos de huevos y frente a fondos complejos.

3. Metodología

a. Definición formal del problema



Sea $D = \{(I_i, N_i)\}_{i=1}^M$ el conjunto de datos, donde $I_i \in \mathbb{R}^{H \times W \times 3}$ es la imagen de una paleta de ovitrampa y $N_i \in \mathbb{Z}_{\geq 0}$ es el conteo real de huevos anotado por un técnico. El problema se resuelve en dos etapas encadenadas:

Etapla 1 — Regresión de conteo. Aprender $f_\theta: I_i \mapsto \hat{N}_i$ minimizando:

$$\theta^* = \arg \min_{\theta} \frac{1}{M} \sum_{i=1}^M \left(\hat{N}_i - N_i \right)^2$$

Etapla 2 — Asignación de clase IDH

(post-procesamiento). Una vez obtenido $\hat{N}_i$, se aplica directamente la tabla de umbrales del MINSa para determinar la categoría de riesgo. Esta etapa no involucra ningún modelo: es una regla determinística equivalente a un condicional:

$$\hat{c}_i = \{\text{Bajo}, \text{si } \hat{N}_i < \tau_1\}$$

$$\hat{c}_i = \{\text{Medio}, \text{si } \tau_1 \leq \hat{N}_i < \tau_2\}$$

$$\hat{c}_i = \{\text{Alto}, \text{si } \tau_2 \leq \hat{N}_i < \tau_3\}$$

$$\hat{c}_i = \{\text{Muy Alto}, \text{si } \hat{N}_i \geq \tau_3\}$$

En resumen: el modelo CNN solo aprende a contar. La clasificación IDH es una consecuencia directa de ese conteo, aplicada fuera del modelo.

b. Preparación de anotaciones

El dataset *dengue-ruehm* (Roboflow, 247 imágenes) provee anotaciones de bounding box $(x_{min}, y_{min}, x_{max}, y_{max})$ por huevo. Se extrae el centroide de cada caja:

$$p_k = \left(\frac{x_{min}^k + x_{max}^k}{2}, \frac{y_{min}^k + y_{max}^k}{2} \right)$$

El conteo de referencia $N_i = |B_i|$ es el número de bounding boxes de la imagen i , sin introducir estimación adicional.

c. Arquitectura del modelo

Se propone una arquitectura CNN con cabeza de regresión. Los tres encoders pre-entrenados en ImageNet (ResNet-50, InceptionV3 y EfficientNet-B3) se adaptan eliminando su capa de clasificación original y añadiendo una cabeza común:

$$\hat{N}_i = \text{ReLU}(w^T \cdot \text{GAP}(F_{enc}(I_i)) + b)$$

donde GAP es Global Average Pooling y ReLU garantiza $\hat{N}_i \geq 0$. Al compartir la misma cabeza, las diferencias de desempeño son atribuibles exclusivamente al encoder.

d. Aumento de datos

Dado que el dataset cuenta con 247 imágenes, se aplica aumentación durante el entrenamiento para incrementar la variabilidad y reducir el sobreajuste. Las transformaciones empleadas se muestran en la Tabla 1. Estas transformaciones no alteran el conteo N_i asociado a la imagen.

Transformación	Rango / Valor
Volteo horizontal y vertical	$p = 0.5$
Rotación aleatoria	$\pm 20^\circ$
Ajuste de brillo	$\pm 15\%$
Ajuste de contraste	$\pm 15\%$
Recorte aleatorio	90–100% del área, relleno por reflexión

Tabla 1: Transformaciones de aumentación de datos aplicadas durante el entrenamiento.

e. Entrenamiento con Transfer Learning

Se aplica fine-tuning en dos fases para compensar el tamaño reducido del dataset:

- **Fase 1 (10 épocas, $lr = 1 \times 10^{-3}$):** encoder congelado; solo se entrena la cabeza de regresión.
- **Fase 2 (hasta 50 épocas, $lr = 1 \times 10^{-4}$):** se descongela el último tercio del encoder con early stopping (paciencia = 10 épocas).

La pérdida es MSE sobre el conteo:

$$L = \frac{1}{B} \sum_{i=1}^B \left(\hat{N}_i - N_i \right)^2$$

El protocolo es idéntico en los tres modelos para asegurar una comparación equitativa.

Hiperparámetro	Valor
Optimizador	Adam
Batch size	16
Scheduler	ReduceLROnPlateau (factor 0.5)
Resolución de entrada	224 × 224 px

Tabla 2: Hiperparámetros comunes a los tres modelos.

4. Experimentación y Resultados

4.1 Análisis comparativo de estabilidad y métricas globales



La evaluación del desempeño numérico se realizó sobre el conjunto de pruebas estáticas tras ejecutar cinco iteraciones completas de entrenamiento independiente por cada arquitectura. Este enfoque permitió medir no sólo la precisión absoluta, sino también la estabilidad de las arquitecturas frente a la estocasticidad de la inicialización de pesos, reportando la media y la desviación estándar para el Error Absoluto Medio (MAE), el Error Cuadrático Medio (RMSE) y la Mediana del Error Absoluto (MdAE).

En la Figura 2, se consolida el análisis de variabilidad mediante diagramas de caja (boxplots) para las tres métricas evaluadas.




Figura 2. Comparación de la distribución del error (MAE, RMSE, MdAE) entre las arquitecturas evaluadas a lo largo de cinco iteraciones independientes.

Los resultados numéricos revelan diferencias categóricas en la capacidad de convergencia. La arquitectura InceptionV3 exhibió el desempeño más deficiente y errático, registrando el mayor error y la varianza más alta con un MAE de 24.78 ± 3.76 y un RMSE de 50.45 ± 9.20 . Este comportamiento evidencia una marcada inestabilidad frente a inicializaciones aleatorias y una alta sensibilidad a la distribución sesgada de los datos, lo que inhabilita su uso para la automatización del conteo.

Por el contrario, ResNet-50 y EfficientNet-B3 demostraron un comportamiento altamente competitivo y una varianza inter-iteración notablemente reducida. ResNet-50 se consolidó como el modelo con el menor error absoluto global, logrando un MAE de 14.12 ± 1.74 y el margen de error central más bajo (MdAE de 4.91 ± 1.58). Por su parte, EfficientNet-B3 obtuvo métricas ligeramente peores en su media de error absoluto (MAE de 16.98 ± 2.33 y RMSE de 28.05 ± 5.89); sin embargo, como se observará en el análisis de valores atípicos, el backbone de EfficientNet-B3 compensa esta ligera diferencia métrica con una superior adaptación matemática frente a aglomeraciones masivas de píxeles como se demuestra su mejor métrica en RMSE que penaliza los errores en valores altos por su potencia de 2 en el cálculo.

4.2 Comportamiento y tolerancia ante densidades críticas (Outliers)

Un desafío intrínseco en la vigilancia entomológica automatizada es el fenómeno de hacinamiento o formación de clústeres masivos de huevos en

ovitrampas de alta infestación. Para evaluar la resiliencia de las redes en escenarios críticos, se analizó el comportamiento de las predicciones en los valores atípicos del conjunto de prueba.

Al evaluar un escenario extremo con una densidad real de 382 huevos anotados en una sola paleta, las respuestas de los modelos entrenados bajo la misma función de pérdida Huber fueron las siguientes: InceptionV3 colapsó subestimando críticamente la muestra al predecir 133 huevos, mientras que ResNet-50 mitigó parcialmente la pérdida de información proyectando 267 unidades. EfficientNet-B3 demostró una capacidad superior de extracción de características complejas y extrapolación geométrica al alcanzar una predicción de 339 huevos. Este resultado valida la hipótesis de que la arquitectura de bloques de EfficientNet-B3, combinada con el escalamiento compuesto, asimila de forma más eficiente el solapamiento de texturas densas, superando las limitaciones de subestimación observadas comúnmente en aproximaciones de regresión lineal simple.

4.3. Validación bajo el criterio de alerta epidemiológica

Para determinar la viabilidad operativa del sistema en el entorno de salud pública, los conteos continuos predichos fueron mapeados hacia las categorías discretas del Índice de Densidad de Huevos (IDH) normadas por el Ministerio de Salud (MINSA): Bajo, Medio, Alto y Muy Alto. En la Figura 3 se presenta la matriz de confusión del modelo EfficientNet-B3, el cual obtuvo el mejor desempeño general.




Figura 3. Matriz de confusión ordinal para la clasificación del Índice de Densidad de Huevos (IDH) empleando la arquitectura con mejor rendimiento operativo.

El análisis de la matriz de confusión ordinal demuestra que los errores numéricos de regresión reportados en las secciones previas no comprometen la efectividad epidemiológica de la herramienta. En el cuadrante de riesgo "Muy Alto", las desviaciones matemáticas (como predecir 339 huevos ante un valor real de 382) se vuelven inocuas en la práctica, debido a que ambas magnitudes se ubican con total certeza dentro del umbral superior de alerta. Consecuentemente, el sistema activaría exactamente los mismos protocolos de fumigación, control vectorial y asignación de presupuesto por parte de las autoridades sanitarias.

Asimismo, se observa que la gran mayoría de las predicciones se concentran estrictamente en la diagonal principal de la matriz. Las escasas clasificaciones erróneas ocurren de manera exclusiva entre niveles de riesgo adyacentes (por ejemplo, transiciones entre riesgo Medio y Bajo), lo cual corresponde a muestras cuyos conteos reales se encuentran inmediatamente en las fronteras de los umbrales definidos. No se registran errores críticos de falso negativo extremo (como clasificar una muestra de riesgo "Muy Alto" como "Bajo"), lo que garantiza la seguridad y confiabilidad del modelo como filtro automatizado para optimizar los tiempos de respuesta frente al vector *Aedes aegypti*.

5. Conclusión

5.1 Resolución de la hipótesis y determinación del modelo óptimo

Se demostró que no existe una única arquitectura que domine de forma absoluta todas las métricas, sino que cada modelo aportaba a la elección final con sus diferentes características. Evaluando el desempeño sobre el conjunto de prueba tras cinco iteraciones independientes, EfficientNet-B3 se definió como la arquitectura con el rendimiento operativo más robusto para la vigilancia epidemiológica. Aunque ResNet-50 exhibió una mayor exactitud en rangos de densidad baja e intermedia, EfficientNet-B3 demostró una superioridad crítica ante el fenómeno de hacinamiento y capacidad para extrapolar texturas complejas en escenarios extremos, convirtiéndola en la opción más segura contra la subestimación en focos críticos de infestación.

5.2 Viabilidad de la estrategia de regresión para la clasificación ordinal

El enfoque metodológico de dos etapas encadenadas (Regresión de conteo global continuo + Asignación determinística de clase IDH) fue viable, eficiente y computacionalmente bueno frente a los paradigmas tradicionales de detección por cajas delimitadoras (*bounding boxes*) o segmentación de instancias. Esta aproximación evita con éxito el cuello de botella del etiquetado masivo en infestaciones severas y anula el impacto negativo del solapamiento físico de las entidades biológicas en el campo microscópico.

5.3 Validación epidemiológica bajo los criterios del MINSA

Se concluye que las desviaciones del modelo de regresión en densidades críticas no comprometen la toma de decisiones, ya que el sistema demostró una clasificación epidemiológica robusta sin registrar falsos negativos extremos que pongan en riesgo la salud pública.

5.4 Inestabilidad estructural y descarte de InceptionV3

Los experimentos permitieron identificar y descartar categóricamente a la arquitectura InceptionV3 para tareas de vigilancia entomológica automatizada porque se registró un desempeño altamente errático y la mayor variabilidad inter-iteración, junto con un

colapso severo ante valores atípicos subestimando críticamente las muestras atípicas de mayor densidad, por eso se demostró que su diseño de ramas paralelas no es capaz de asimilar distribuciones de datos altamente sesgadas ni el solapamiento severo de cuerpos oscuros y opacos sobre las paletas de ovitrampas.

5.5 Robustez metodológica mediante evaluación de estabilidad

La incorporación de un protocolo de evaluación basado en cinco ejecuciones independientes con inicialización estocástica de pesos permitió obtener valores más confiables que las estáticas puntuales, dotando al estudio de rigor estadístico. La reducción de la varianza inter-iteración en los boxplots de estabilidad para ResNet-50 y EfficientNet-B3 demuestra que ambas redes, complementadas con la técnica de parada temprana y el optimizador Adam, logran una convergencia altamente reproducible y robusta, independientemente de las condiciones aleatorias iniciales del entrenamiento.

6. Sugerencias de trabajos futuros

Para tener un *pipeline* más robusto y una aplicabilidad real, se debe diversificar los datos y reducir la dependencia de imágenes microscópicas. Se sugiere incorporar *datasets* macroscópicos capturados en campo con teléfonos celulares; iniciativas recientes como *Col-Ovo* (Almanza y Montenegro, 2026) han validado exitosamente el uso de bases de datos móviles con ovitrampas para entrenar modelos robustos al ruido visual, sombras y baja resolución. Por otro lado, para mitigar el decaimiento crítico del rendimiento ante el solapamiento y aglomeración masiva de huevos, se propone abordar la tarea mediante mapas de densidad. Esta técnica, pilar en el estado del arte del conteo de multitudes (*crowd counting*), estima una distribución espacial continua en lugar de aislar *bounding-boxes*, superando con éxito la alta congestión visual (Zhang et al., 2016; Li et al., 2018). Finalmente, el enfoque podría expandirse para resolver un nuevo problema epidemiológico: clasificar la viabilidad biológica del vector (huevos eclosionados vs. intactos) para medir automáticamente el impacto de las fumigaciones.

7. Implicancias éticas

7.1 Equidad en la asignación de recursos y mitigación del sesgo algorítmico

En el contexto de la vigilancia entomológica automatizada del vector *Aedes aegypti*, los errores de predicción numérica trascienden el ámbito estadístico y adquieren repercusiones éticas directas sobre la salud pública. Una subestimación sistemática de la densidad de huevos por parte de un modelo entrenado, fenómeno observado en modelos con alta inestabilidad algorítmica ante concentraciones masivas de ovitrampas, daría lugar a una clasificación errónea del Índice de Densidad de Huevos (IDH). Si una zona con infestación crítica de riesgo "Muy Alto" es catalogada de forma equivocada bajo un nivel inferior (como riesgo Medio o Alto), las autoridades del

Ministerio de Salud (MINSA) retrasarían las intervenciones de control vectorial, fumigación y distribución presupuestaria. Esto expondría de manera desproporcionada a las comunidades vulnerables a brotes epidémicos de dengue. Por el contrario, una sobreestimación artificial de los conteos podría provocar una asignación ineficiente de insecticidas y personal en sectores de bajo riesgo, desabasteciendo a regiones que realmente requieren atención urgente. Por ende, la selección de arquitecturas robustas y estables como ResNet-50 y EfficientNet-B3 junto con funciones de pérdida estables como la pérdida Huber constituye una responsabilidad ética indispensable para garantizar una distribución justa y equitativa de los recursos sanitarios del Estado peruano.

7.2 Transparencia, explicabilidad y la responsabilidad de la "caja negra"

El despliegue de Redes Neuronales Convolucionales introduce el dilema ético de la opacidad algorítmica. Al operar como modelos de "caja negra", las operaciones matemáticas internas de los bloques convolucionales que conducen a una estimación numérica final no resultan legibles ni auditables directamente por los biólogos o inspectores sanitarios. Confiar ciegamente en estas decisiones automatizadas para decretar alertas epidemiológicas sin una comprensión de los criterios de extracción de características plantea riesgos éticos en la gobernanza de la salud. Para mitigar esta opacidad, el diseño del sistema no debe plantearse como una entidad autónoma de decisión final, sino como una herramienta de soporte que mantenga la trazabilidad de sus estimaciones. Ello exige el establecimiento de protocolos de auditoría periódica donde muestras catalogadas en las fronteras de los umbrales del IDH sean validadas manualmente por especialistas, asegurando que la responsabilidad última de las políticas preventivas permanezca bajo el arbitrio y supervisión humana.

7.3 Privacidad de datos geoespaciales y prevención de la estigmatización comunitaria

La recolección de paletas de ovitrampas se realiza mediante inspecciones directamente en el ámbito residencial y domiciliario de los ciudadanos. Aunque las imágenes procesadas por los modelos se restringen estrictamente a las texturas de las paletas para efectuar el conteo de los huevos, los metadatos asociados a dichas muestras (tales como coordenadas GPS exactas, nombres de los propietarios de los predios o fotografías accidentales del entorno de las viviendas) involucran serios desafíos de privacidad. La filtración o el uso inadecuado de esta información geoespacial detallada podría derivar en la estigmatización social y económica de barrios, distritos o familias específicas, etiquetándolas públicamente como focos insalubres de infección del dengue. Desde una perspectiva ética, se vuelve imperativo implementar mecanismos estrictos de anonimización y disociación de datos antes de que las imágenes ingresen al flujo de entrenamiento o inferencia. La localización del riesgo debe gestionarse a nivel macro (sectores o distritos ecológicos) en los sistemas de

información geográfica del MINSA, salvaguardando la identidad y la dignidad de los hogares inspeccionados.

7.4 Sostenibilidad socio-laboral y el enfoque de complemento humano (Human-in-the-Loop)

La automatización del conteo de huevos mediante visión artificial impacta directamente la dinámica laboral de los técnicos de campo y personal de laboratorio, quienes históricamente ejecutan esta labor mediante un proceso manual, tedioso y propenso a la fatiga ocular. La introducción de esta tecnología no debe promoverse éticamente bajo un discurso de sustitución laboral masiva o abaratamiento de costos de capital humano, sino bajo un enfoque de complementariedad o aumento de capacidades (human-in-the-loop). Al delegar la tarea repetitiva y mecánicamente desgastante del conteo a los modelos computacionales, el personal calificado puede redirigir su tiempo y experiencia hacia actividades estratégicas de mayor valor, tales como el análisis epidemiológico de tendencias, la ejecución inmediata de los cercos sanitarios en las comunidades y la educación preventiva de la población. La ética tecnológica en este enfoque radica en dignificar el trabajo sanitario, transformando un cuello de botella operativo en una capacidad de respuesta rápida frente a la emergencia del vector.

8. Link del repositorio del trabajo

Repositorio público de GitHub:
[cnn-ordinal-classifier-egg-ovitrapp](https://github.com/cnn-ordinal-classifier-egg-ovitrapp)

9. Declaración de contribución de cada integrante

- Rodrigo Carbajal: Responsable de la redacción de la sección Introducción, hipótesis y objetivos. Buscó y seleccionó del conjunto de datos (dataset) utilizado, así como la recopilación y estructuración del estado del arte general del problema. Asimismo, desarrolló el código base para la lectura de datos, el preprocesamiento y la implementación de técnicas de Data Augmentation adaptadas a partir de las funciones matemáticas reportadas en la literatura. Finalmente, identificó y redactó las proyecciones y mejoras del proyecto en la sección Sugerencias de trabajos futuros.
- Nassim Ramirez: Encargado de la redacción y citación en la sección de Trabajos Relacionados, enfocándose específicamente en el análisis del artículo científico de Vicente. Realizó la revisión y corrección técnica del apartado de Experimentación y Resultados en lo concerniente a la arquitectura ResNet-50. Adicionalmente, redactó las Conclusiones finales fundamentadas en la comparación integral de los modelos.
- Gonzalo Ipanaque: Responsable de la investigación, redacción y citación de fuentes dentro de la sección de Trabajos Relacionados. Diseñó, programó y entrenó el modelo basado en la arquitectura EfficientNet-B3. Asimismo,



se encargó de la redacción del Resumen del informe.

- Jorge Chamorro: Encargado de la investigación y citación de la sección de Trabajos Relacionados. Redactó de manera integral los apartados de Experimentación y Resultados e Implicancias Éticas. Desarrolló la evaluación comparativa de las métricas de rendimiento y generó las visualizaciones y gráficos estadísticos del reporte. Adicionalmente, actuó como revisor principal del proyecto, asegurando la cohesión y validez de la redacción del informe, el código fuente y la presentación oral.
- Pedro Chavez: Responsable de la redacción estructurada de la sección de Metodología. Diseñó, configuró y entrenó el modelo bajo la arquitectura InceptionV3. Adicionalmente, realizó la integración y consolidación de los módulos de código de todo el equipo en un repositorio unificado a través de un script ejecutable principal (main), encargándose de la ejecución global del proyecto y de la extracción de los resultados consolidados.

10. Declaración de uso de IA

Se usó Gemini para corregir errores ortográficos. Todos los integrantes validaron y corrigieron lo generado por la inteligencia artificial generativa en base a lo que redactaron previamente.

11. Referencias

- [1]. Almanza, J. y Montenegro, D. (2026). Col-Ovo: Smartphone-based artificial intelligence for rapid counting of Aedes mosquito eggs under field conditions. *bioRxiv*. <https://doi.org/10.64898/2026.03.19.712860>
- [2]. CENTRO NACIONAL DE EPIDEMIOLOGÍA, PREVENCIÓN Y CONTROL DE ENFERMEDADES (CDC PERÚ) (2026). Sala de situación de dengue. Semana Epidemiológica 14 [informe]. Lima. Consulta: 31 de mayo de 2026. <https://www.dge.gob.pe/portal/docs/vigilancia/sala/2026/SE14/dengue.pdf>
- [3]. CENTRO NACIONAL DE EPIDEMIOLOGÍA, PREVENCIÓN Y CONTROL DE ENFERMEDADES (CDC PERÚ) 2024 "CDC Perú emite alerta epidemiológica por incremento de casos de dengue en el Perú". En *Centro Nacional de Epidemiología, Prevención y Control de Enfermedades*. Consulta: 31 de mayo de 2026. <https://www.dge.gob.pe/portalnuevo/informacion-publica/prensa/cdc-peru-emite-alerta-epidemiologica-por-incremento-de-casos-de-dengue-en-el-peru/>
- [4]. Javed, N., López-Denman, A. J., Paradkar, P. N., & Bhatti, A. (2023). EggCountAI: a convolutional neural network-based software for counting of Aedes aegypti mosquito eggs. *Parasites & Vectors*, 16(1), 341. <https://doi.org/10.1186/s13071-023-05956-1>
- [5]. Leopoldo, I. M., & Leones, J. P. (2025). A Stacked Transfer Learning Approach for Accurate Classification of Soil-Transmitted Helminth Eggs Using YOLOv8 and ResNet50. 2025 5th International Conference on Communication Technology and Information Technology (ICCTIT), 1-6. <https://doi.org/10.1109/ICCTIT68197.2025.11406451>
- [6]. Li, Y., Zhang, X. y Chen, D. (2018). CSRNet: Dilated convolutional neural networks for understanding the highly congested scenes. En *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 1091-1100). https://doi.ieeecomputersociety.org/10.1109/CVP_R.2018.00120
- [7]. MINISTERIO DE SALUD DEL PERÚ (MINSA) 2023 Resolución Ministerial N.º 228-2023-MINSA. Lima. Consulta: 31 de mayo de 2026. <https://www.gob.pe/institucion/minsa/normas-legales/3957960-228-2023-minsa>
- [8]. MINISTERIO DE SALUD DEL PERÚ (MINSA) 2016. *Protocolo sanitario de urgencia para el reforzamiento de la vigilancia entomológica del vector Aedes aegypti mediante el uso de ovitrampas para establecimientos de salud* [Resolución Ministerial N.º 010-2015/MINSA]. Lima. Consulta: 31 de mayo de 2026. <https://www.gob.pe/es/i/284845>
- [9]. Nui pian, W., Meesad, P., & Kanjanawattana, S. (2024). A comparative ResNet-50, InceptionV3 and EfficientNetB3 with retinal disease. *Proceedings of the 2023 7th International Conference on Natural Language Processing and Information Retrieval*, 283-287. <https://doi.org/10.1145/3639233.3639337>
- [10]. Vicente, M. N. d. O., Porto, J. V. d. A., Higa, G. T. H., Nucci, H. H. P., Santana, A. B., Porto, K. R. d. A., Roel, A. R., & Pistori, H. (2025). Aedes aegypti Egg Counting with Neural Networks for Object Detection. *Revista de Informática Teórica e Aplicada*, 32(1), 287-293. <https://doi.org/10.22456/2175-2745.143494>
- [11]. Zhang, Y., Zhou, D., Chen, S., Gao, S. y Ma, Y. (2016). Single-image crowd counting via multi-column convolutional neural network. En *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 589-597). https://doi.ieeecomputersociety.org/10.1109/CVP_R.2018.00120

